

Universidade de São Paulo
Escola de Engenharia de São Carlos

Uso de aprendizado de máquina para beamforming aeroacústico

Guilherme Hiroshi Sinoara

Universidade de São Paulo
Escola de Engenharia de São Carlos

27 de janeiro de 2025

Sumário

- 1 Introdução
- 2 Objetivos
- 3 Justificativa
- 4 Referencial Teórico
- 5 Metodologia
- 6 Resultados preliminares
- 7 Referências

Introdução

Beamforming




Figura: Esquemático de beamforming para um aerofólio. Fonte: (ARCONDOULIS et al., 2010)

Introdução

Beamforming e Aprendizado de Máquina



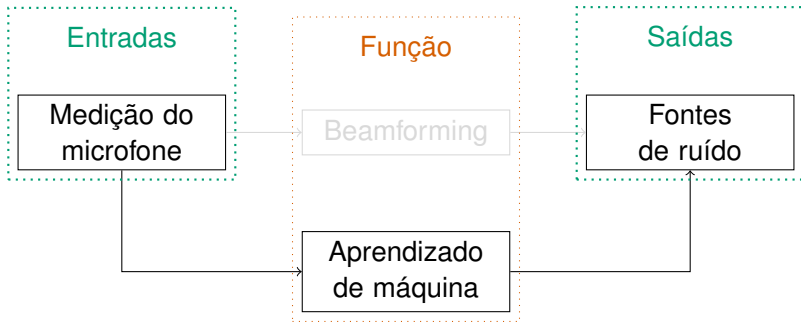
Introdução

Beamforming e Aprendizado de Máquina



Introdução

Beamforming e Aprendizado de Máquina



Objetivos

Avaliar o uso de modelos de aprendizado de máquina no processamento de sinais em experimentos de aeroacústica;

- 1 Comparar o impacto do tamanho do conjunto de dados de treinamento no desempenho do modelo;
- 2 Comparar o impacto de diferentes hiperparâmetros no desempenho do modelo;
- 3 Comparar a acurácia do modelo com a de métodos tradicionais de beamforming;
- 4 Comparar o tempo computacional com o de métodos tradicionais de beamforming;

Justificativa

Os métodos de beamforming são computacionalmente intensos, principalmente quando usados com algoritmos de deconvolução (CARRANZA, 2022).

Sendo uma função que mapeia as leituras dos microfones às fontes de ruído, são candidatos a serem substituídos por aprendizado de máquina.

Ademais, as redes neurais podem ser projetadas de modo a diminuir a interferência de ruído, (IBIAS et al., 2024) aumentando sua acurácia.

Referencial Teórico

Aeroacústica linear

Para calcular a pressão sonora causada por uma fonte na posição y em um microphone na posição x , serão usadas as seguintes relações (GLEGG; DEVENPORT, 2023):

$$r = |x - y| \quad (1)$$

x posição do microfone

y posição da fonte

r distância entre a fonte e o microfone

$$\hat{A} = A \exp(i\phi) = A(\cos \phi + i \sin \phi) \quad (2)$$

\hat{A} amplitude complexa na fonte

A amplitude máxima na fonte

ϕ fase da onda

Referencial Teórico

Aeroacústica linear

$$\hat{p} = \frac{\hat{A} \exp(ikr)}{r} \quad (3)$$

$$k = \frac{\omega}{c} \quad (4)$$

\hat{p} amplitude complexa no ponto x

ω frequência da onda

k número de onda (inverso do comprimento de onda)

c velocidade da onda no meio

Referencial Teórico

Redes Neurais




Figura: Exemplo de rede neural artificial. Fonte: Elaborada pelo autor.

Referencial Teórico

Redes Neurais





Figura: Modelo de neurônio. Fonte: Elaborada pelo autor.

Figura: Esquemático de exemplo de grade de pontos focais e microfones



Fonte: Elaborada pelo autor.


Os hiperparâmetros a serem testados são:

- Separação de treino e teste;
- Número de camadas escondidas;
- Número de neurônios em cada camada escondida;
- Número de pares no conjunto de dados;
- Porcentagem de pares para treino;

Resultados preliminares

Para os testes preliminares foi usada uma grade 6×6 pontos focais e 5 microfones em linha logo abaixo:

Figura: Grade usada para os testes preliminares



Fonte: Elaborada pelo autor.

Resultados preliminares

Hiperparâmetros

Os hiperparâmetros a serem testados são:

- Número de camadas escondidas: [1]
- Número de neurônios em cada camada escondida:
[1, 2, 4, 8, 16, 32, 64, 128, 256, 512, 1024];
- Número de pares no conjunto de dados:
[100, 180, 325, 585, 1054, 1898, 3420, 6162, 11101, 20000]
- Porcentagem de pares para treino: [0.25, 0.5, 0.75]
- Taxa de aprendizado: [$1.00e - 2$, $5.62e - 3$, $3.16e - 3$, $1.78e - 3$, $1.00e - 3$, $5.00e - 4$, $3.16e - 4$, $2.00e - 4$, $1.41e - 4$, $1.00e - 4$, $5.00e - 5$]

Resultados preliminares

Treinamento

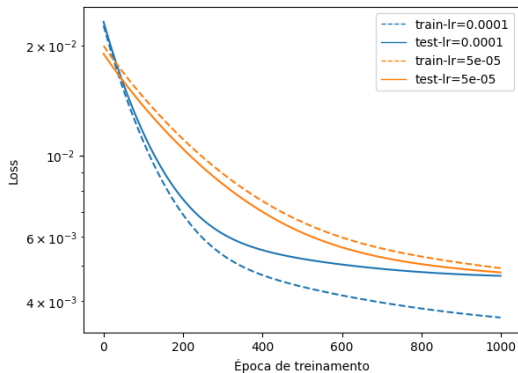


Figura: Treinamento com 32 neurônios e 585 pares de treinamento. Fonte: Elaborada pelo autor.

Resultados preliminares

Treinamento




Figura: Treinamento com 1024 neurônios e 585 pares de treinamento mostrando overfitting.

Fonte: Elaborada pelo autor.

Resultados preliminares

Overfitting








Figura: Regiões de overfitting. Fonte: Elaborada pelo autor.

Referências I

 ARCONDOULIS, E. et al. Design and calibration of a small aeroacoustic beamformer. 01 2010.

 CARRANZA, D. M. *High-Resolution Localization of Aeroacoustic Sources Using Advanced Phased Array Setups*. Tese (Doutorado) — UC Irvine, 2022.

 GLEGG, S.; DEVENPORT, W. *Aeroacoustics of low mach number flows*. 2. ed. San Diego, CA: Academic Press, 2023.

 IBIAS, A. et al. *Improving Noise Robustness through Abstractions and its Impact on Machine Learning*. 2024. Disponível em: <<https://arxiv.org/abs/2406.08428>>.